

Procesamiento de Lenguaje Natural:

¿Cómo entienden las computadoras el lenguaje humano?

Mauricio Toledo-Acosta
mauricio.toledo@unison.mx

Departamento de Matemáticas
Universidad de Sonora



Section 1

Introducción



¿Qué es el Procesamiento de Lenguaje Natural?

El **Procesamiento de Lenguaje Natural (PLN)** es un campo interdisciplinario que combina:

- Ciencias de la computación
- Lingüística computacional
- Aprendizaje automático e Inteligencia artificial

Objetivo: Permitir que las computadoras comprendan, interpreten y generen lenguaje humano de manera útil.



El Lenguaje Natural

Un **lenguaje natural** es cualquier lenguaje que surge espontáneamente en una comunidad humana a través del uso, la repetición y el cambio.

Características principales:

- Evoluciona naturalmente (no es diseñado) ...
- Se distingue de lenguajes formales (programación, lógica)
- Es inherentemente ambiguo y contextual



Niveles de Análisis en PLN

El análisis del lenguaje natural ocurre en múltiples niveles:

- **Fonético/Fonológico:** Sonidos del habla
- **Morfológico:** Estructura de las palabras
- **Léxico:** Vocabulario y significado de palabras
- **Sintáctico:** Estructura gramatical de oraciones (*Mi niñas duerme tranquilo*)
- **Semántico:** Significado de oraciones y textos (*Incoloras ideas verdes duermen furiosamente*)
- **Discursivo:** Coherencia entre oraciones y párrafos



Principales Desafíos del PLN

¿Por qué es difícil procesar el lenguaje natural?

- **Ambigüedad:** Una palabra puede tener múltiples significados
 - *Banco* (institución financiera vs. asiento)
 - *Vi al niño con los binoculares* (¿quién tiene los binoculares?)
- **Variabilidad:** Dialectos, jerga, estilos personales
- **Contexto:** El significado depende de la situación
- **Implicitación:** Mucha información queda sobreentendida



Principales Desafíos del PLN

- **Correferencia:** ¿A qué se refieren los pronombres?
 - "María le dio un libro a Ana. Ella lo leyó rápidamente."
- **Lenguaje figurado:** Ironía, sarcasmo, metáforas
- **Ruido:** Errores tipográficos, gramaticales
- **Multilingüismo:** Textos en varios idiomas
- **Evolución constante:** Nuevas palabras, expresiones



Principales Tareas del PLN

Tareas de comprensión:

- Análisis de sentimientos y clasificación
- Modelado de tópicos
- Identificación de autoría
- Extracción de información
- Reconocimiento de Entidades Nombradas (NER)

Tareas de generación:

- Traducción automática
- Generación de texto
- Resumen automático
- Paráfrasis



Principales Tareas del PLN

Tareas de comprensión:

- Análisis de sentimientos y clasificación
- Modelado de tópicos
- Identificación de autoría
- Extracción de información
- Reconocimiento de Entidades Nombradas (NER)

Tareas de generación:

- Traducción automática
- Generación de texto
- Resumen automático
- Paráfrasis



Enfoques y Soluciones

La complejidad de la solución depende de la tarea:

- **Enfoques basados en reglas:** Expresiones regulares, reglas gramaticales
- **Métodos estadísticos:** N -gramas, modelos probabilísticos
- **Aprendizaje automático:** SVM, árboles de decisión
- **Deep Learning:** Redes neuronales, transformers, BERT
- **Large Language Models:** Claude, GPT, DeepSeek, Kimi, ...

Usar la herramienta adecuada para cada problema.



Aplicaciones del PLN en el Mundo Real

Vida cotidiana:

- Asistentes virtuales
- Traducciones automáticas
- Corrección ortográfica
- Búsquedas web

Industria:

- Análisis de redes sociales
- Atención al cliente automatizada
- Análisis de documentos legales
- Investigación biomédica



Section 2

El PLN en la actualidad



Ejemplos de PLN: Llenado de formas

Name form

* Required

Email *

Cannot pre-fill email

Name

Your answer

[Get link](#)

Contacts

Name

Phone

Area

Address

City

State

Zip

Email

Birthday



Ejemplos de PLN: Llenado de formas

Name form

* Required

Email *

Cannot pre-fill email

Name

Your answer

Get link

Contacts

Name

Phone Area

Address

City

State Zip

Email

Birthday

Retos: Mayúsculas/mínusculas, caracteres invalidos, formatos.



Ejemplos de PLN: Búsquedas



Ejemplos de búsqueda: Búsqueda 1, Búsqueda 2, Búsqueda 3

Retos: Mayúsculas/mínusculas, sintaxis, typos, caracteres invalidos, semántica etc.

BERT en las búsquedas



Ejemplos de PLN: Large Language Models

Los LLMs son modelos de lenguaje entrenados en grandes cantidades de documentos para comprender y generar lenguaje humano de manera coherente. Estos modelos pueden realizar múltiples tareas sin entrenamiento específico adicional: mantener conversaciones, responder preguntas, traducir entre idiomas, resumir documentos y asistir en tareas de análisis textual.

Su principal fortaleza radica en su capacidad de generalización: pueden adaptarse a contextos diversos y generar respuestas apropiadas incluso ante situaciones que no encontraron explícitamente durante su entrenamiento.

Detección de texto generado por AI



Benchmarks comparativos de LLMs (2024)

- **Examen SAT (Reading/Writing):** GPT-4: 1410/1600 (94%) (OpenAI, 2023)
- **USMLE (Medicina):**
 - GPT-4: 75% correctas (Gilson et al., 2023)
 - Med-PaLM 2 (Gemini): 86.5% (Google, 2023)
- **MBE (Examen de Barra Multiestatal):** Claude 3 Opus: 85% (0-shot CoT) (Tabla 2, Anthropic, 2024)
- **MMLU (Multitarea):**
 - Gemini 1.5 Pro: 91.1% (Google, 2024)
 - Llama 3 70B: 82.0% (Meta, 2024)

Fuentes adicionales: LMArena.



Alucinaciones y otros problemas

- **Alucinaciones factuales:**

- Acerca de si los dinosaurios construyeron una civilización:
Some species of dinosaurs even developed primitive forms of art, such as engravings on stones. Corrección
- When did Leonardo da Vinci paint the Mona Lisa? *Leonardo da Vinci painted the Mona Lisa in 1815.* Corrección

- **Puede inventar referencias:** En este ejemplo un LLM da referencias sobre puntajes de modelos en pruebas médicas.

- Claude 3 Opus: 76.5% (Katz et al., 2024)
- GPT-4: 75% (Katz et al., 2023)



Alucinaciones y otros problemas

- **Puede reproducir sesgos:**
 - Ante la misma enfermedad, es más probable que recomiende un trasplante de riñón a un hombre blanco que a una mujer negra.
 - Ante la pregunta "¿Quién es mejor en matemáticas, un niño o una niña?", puede inclinarse por el niño (Sección 7.3, Anthropic, 2024)
- **Respuestas inapropiadas:** Gemini, Claude.



Tendencias en la investigación

Ver los últimos trabajos destacados presentados en la North American Chapter of the Association for Computational Linguistics.

Artículos publicados

¿Qué temáticas y tendencias observas?



Section 3

Temario

Temario

- ① Introducción:
 - Tareas del NLP
 - Expresiones regulares
- ② Métodos de modelado clásico de NLP
 - N-gramas.
 - Modelos BOW (1954), TF-IDF (1970s).
- ③ Algoritmos Clásicos del NLP
 - Naive Bayes (late 1700s -)
 - Latent Dirichlet Allocation (2000)
 - Latent Semantic Analysis (1988)



Temario

- 5 Métodos de redes neuronales de NLP
 - Embeddings de tokens y documentos.
 - Redes recurrentes y LSTM.
 - Modelos Word2Vec (Google, 2013), Glove (Stanford, 2014), FastText (FB, 2016), Doc2Vec (Google, 2014), WordRank (2016).
- 6 Transformadores y LLM.
 - Arquitectura Transformers (2017): *Attention is all you need*.
 - BERT (Google, 2018), RoBERTa (FB, 2019), T5 (2020), LLaMA (Meta AI, 2022), GPT-4 (Open AI, 2023), Qwen3 (2025).
 - Afinación de modelos pre-entrenados.
 - Prompt Engineering, Few shot learning.
 - Retrieval Augmented Generation (RAG).
 - Optimización de Modelos: LoRA (Low-Rank Adaptation), Destilación, Cuantización, Bias evaluation.



Tareas a realizar

- Limpieza de texto y preprocesamiento.
- Análisis de Sentimientos y Clasificación.
- Modelaje de tópicos.
- Information Retrieval.

